

Laboratorio: Trabajo con Funciones en Bases de Datos (SQL Functions)

Atributo	Detalle
Dificultad	Intermedio
Tiempo Estimado	45 minutos
Servicios Principales	Amazon EC2 (Command Host), MySQL Engine, SQL Functions

Resumen y Objetivos

Este laboratorio profundiza en el uso de funciones integradas de SQL para el procesamiento, manipulación y resumen de datos. Aprenderás a transformar información cruda en métricas de valor y a realizar limpiezas de cadenas de texto directamente desde el motor de base de datos.

Al finalizar este laboratorio, serás capaz de:

1. Utilizar funciones de agregación (**SUM**, **MIN**, **MAX**, **AVG**, **COUNT**) para generar reportes estadísticos.
 2. Emplear **SUBSTRING_INDEX()** para segmentar datos complejos en columnas individuales.
 3. Aplicar funciones de limpieza y medición como **TRIM()** y **LENGTH()**.
 4. Eliminar redundancias en los resultados mediante la función **DISTINCT()**.
 5. Integrar funciones tanto en la proyección de resultados (**SELECT**) como en los filtros (**WHERE**).
-


Análisis del Escenario

El equipo de operaciones de base de datos requiere reportes avanzados sobre la base de datos **world**. El diagnóstico inicial indica que, además de las consultas básicas, es necesario realizar limpieza de datos (remover espacios en blanco) y segmentación de regiones geográficas que actualmente se encuentran concatenadas en una sola columna. Como ingeniero, tu tarea es utilizar el poder de procesamiento del motor de base de datos para entregar resultados ya formateados y calculados.

Arquitectura

La infraestructura se basa en una arquitectura de cliente-servidor simplificada:

- **Host de Comandos (EC2):** Actúa como la interfaz administrativa.
- **Motor MySQL:** Ejecuta la lógica de las funciones solicitadas.
- **Dataset:** Tablas **city**, **country** y **countrylanguage** con datos regionales de Finlandia y el mundo.




Desarrollo de las Tareas Paso a Paso


Tarea 1: Conexión al Command Host

Establece la comunicación con el entorno de base de datos a través de la consola de AWS.

1. Navega a la consola de **Amazon EC2**.
2. En el panel de navegación izquierdo, selecciona **Instances** (Instancias).
3. Selecciona la instancia etiquetada como **Command Host** y haz clic en **Connect** (Conectar).



4. Elige la pestaña **Session Manager** y pulsa **Connect**.




5. Configura tu sesión de terminal:

```
sudo su
cd /home/ec2-user/
```

6. Inicia la sesión en el cliente de base de datos:

```
mysql -u root --password='re:St@rt!9'
```



```
sh-4.2$ sudo su
[root@ip-10-1-11-157 bin]# cd /home/ec2-user/
[root@ip-10-1-11-157 ec2-user]# mysql -u root --password='re:St@rt!9'
Welcome to the MariaDB monitor.  Commands end with ; or \g.
Your MariaDB connection id is 5
Server version: 10.5.29-MariaDB MariaDB Server

Copyright (c) 2000, 2018, Oracle, MariaDB Corporation Ab and others.

Type 'help;' or '\h' for help. Type '\c' to clear the current input statement.

MariaDB [(none)]>
```

Tarea 2: Consulta de la Base de Datos **world**

Ejecutarás las funciones para transformar la salida de los datos.

Uso de Funciones de Agregación

1. Calcula el resumen demográfico global de la tabla **country**:

```
SELECT sum(Population), avg(Population), max(Population), min(Population),
count(Population) FROM world.country;
```

- **SUM()**: Total de habitantes.
- **AVG()**: Promedio de población por país.
- **MAX() / MIN()**: Países con mayor y menor población.
- **COUNT()**: Cantidad de registros con datos válidos.

Instances | EC2 | us-west-2

Systems Manager | us-west-2

+

us-west-2.console.aws.amazon.com/systems-manager/session-manager/i-0024398964ee36267?region=us-west-2#

Session ID: user4865988=Alejandro_Barrenechea-fz6ddcguy9k7nx8cove3r8gq2e Shortcuts Instance ID: i-0024398964ee36267

```
sh-4.2$ sudo su
[root@ip-10-1-11-157 bin]# cd /home/ec2-user/
[root@ip-10-1-11-157 ec2-user]# mysql -u root --password='re:St@rt!9'
Welcome to the MariaDB monitor.  Commands end with ; or \g.
Your MariaDB connection id is 5
Server version: 10.5.29-MariaDB MariaDB Server

Copyright (c) 2000, 2018, Oracle, MariaDB Corporation Ab and others.

Type 'help;' or '\h' for help. Type '\c' to clear the current input statement.

MariaDB [(none)]> SELECT sum(Population), avg(Population), max(Population), min(Population), count(Population) FROM world.country;
+-----+-----+-----+-----+-----+
| sum(Population) | avg(Population) | max(Population) | min(Population) | count(Population) |
+-----+-----+-----+-----+-----+
| 6078749450 | 25434098.1172 | 1277558000 | 0 | 239 |
+-----+-----+-----+-----+-----+
1 row in set (0.003 sec)

MariaDB [(none)]>
```

Manipulación de Cadenas de Texto (Strings)

- 2. Divide la columna **Region** para obtener solo la primera palabra (delimitada por un espacio):

SELECT Region, substring_index(Region, " ", 1) FROM world.country;

Instances | EC2 | us-west-2

Systems Manager | us-west-2

+

us-west-2.console.aws.amazon.com/systems-manager/session-manager/i-0024398964ee36267?region=us-west-2#

Session ID: user4865988=Alejandro_Barrenechea-fz6ddcguy9k7nx8cove3r8gq2e Shortcuts Instance ID: i-0024398964ee36267 Terminate

```
MariaDB [(none)]> SELECT Region, substring_index(Region, " ", 1) FROM world.country;
+-----+-----+
| Region | substring_index(Region, " ", 1) |
+-----+-----+
| Caribbean | Caribbean |
| Southern and Central Asia | Southern |
| Central Africa | Central |
| Caribbean | Caribbean |
| Southern Europe | Southern |
| Southern Europe | Southern |
| Caribbean | Caribbean |
| Middle East | Middle |
| South America | South |
| Middle East | Middle |
| Polynesia | Polynesia |
| Antarctica | Antarctica |
| Caribbean | Caribbean |
| Australia and New Zealand | Australia |
| Western Europe | Western |
| Middle East | Middle |
| Eastern Africa | Eastern |
| Western Europe | Western |
| Western Africa | Western |
| Western Africa | Western |
| Southern and Central Asia | Southern |
| Eastern Europe | Eastern |
| Middle East | Middle |
| Caribbean | Caribbean |
| Southern Europe | Southern |
| Eastern Europe | Eastern |
| Central America | Central |
| North America | North |
| South America | South |
| South America | South |
| Caribbean | Caribbean |
| Southeast Asia | Southeast |
| Southern and Central Asia | Southern |
| Antarctica | Antarctica |
| Southern Africa | Southern |
| Central Africa | Central |
| North America | North |
| Australia and New Zealand | Australia |
| Western Europe | Western |
| South America | South |
| Eastern Asia | Eastern |
| Western Africa | Western |
| Central Africa | Central |
| Central Africa | Central |
| Central Africa | Central |
| Polynesia | Polynesia |
| South America | South |
| Eastern Africa | Eastern |
| Western Africa | Western |
| Central America | Central |
| Caribbean | Caribbean |
| Australia and New Zealand | Australia |
| Caribbean | Caribbean |
| Middle East | Middle |
```

```

Session ID: user4865988-Alejandro_Barronchea-fz6ddguy9k7n8cove5r8gq2e Instance ID: i-0024398964ee362677region=us-west-2#
Shortcuts
MariaDB [(none)]>
239 rows in set (0.000 sec)

```

3. Filtra registros utilizando una función dentro de la cláusula **WHERE** para encontrar regiones que comiencen con la palabra "Southern":

```
SELECT Name, Region FROM world.country WHERE substring_index(Region, " ", 1) = "Southern";
```


Limpieza y Conteo de Caracteres

4. Identifica regiones cuyos nombres tengan menos de 10 caracteres, eliminando espacios accidentales al inicio o final:

```
SELECT Region FROM world.country WHERE LENGTH(TRIM(Region)) < 10;
```

5. Notarás resultados duplicados. Aplica la función **DISTINCT()** para obtener una lista única de estas regiones:

```
SELECT DISTINCT(Region) FROM world.country WHERE LENGTH(TRIM(Region)) < 10;
```



Challenge (Desafío Técnico)

Instrucción: Escribe una consulta para los registros que tengan "Micronesia/Caribbean" en la columna de región. El resultado debe dividir el nombre en dos columnas separadas: una llamada **Region Name 1** y otra **Region Name 2**.

Procedimiento Sugerido: Debes identificar el delimitador (en este caso /) y usar la posición 1 para la primera parte y -1 para la última.

Solución:

```
SELECT
    substring_index(Region, "/", 1) AS "Region Name 1",
    substring_index(Region, "/", -1) AS "Region Name 2"
FROM world.country
WHERE Region = 'Micronesian/Caribbean';
```

Resolución del Challenge y Depuración de Consultas

En entornos de ingeniería de datos, es común enfrentarse al resultado **Empty set**. Esto indica que la consulta es sintácticamente válida pero no existen registros que coincidan exactamente con el criterio del **WHERE**.

Diagnóstico del Error "Empty set"

Si al ejecutar la consulta para **Micronesian/Caribbean** obtuviste un conjunto vacío, se debe a una discrepancia entre el valor literal escrito en la consulta y el valor almacenado en el motor MariaDB/MySQL.

Procedimiento de Depuración y Resolución

1. **Identifica el valor real en la base de datos:** Ejecuta una búsqueda de patrón flexible para confirmar la escritura exacta de la región (notarás que el registro correcto es **Micronesia/Caribbean** sin la "n" final en Micronesia):

```
SELECT DISTINCT Region FROM world.country WHERE Region LIKE '%Carib%';
```

2. **Ejecuta la consulta corregida del Challenge:** Utiliza el nombre exacto identificado y aplica la lógica de segmentación con los alias solicitados:

```
SELECT
    substring_index(Region, "/", 1) AS "Region Name 1",
    substring_index(Region, "/", -1) AS "Region Name 2"
FROM world.country
WHERE Region = 'Micronesia/Caribbean';
```

3. **Implementa una consulta robusta (Buena Práctica de Ingeniería):** Para evitar fallos por espacios accidentales o variaciones mínimas, utiliza la función **TRIM()** y el operador **LIKE**. Esta es la forma más profesional de asegurar el resultado:

```
SELECT
    substring_index(TRIM(Region), "/", 1) AS "Region Name 1",
    substring_index(TRIM(Region), "/", -1) AS "Region Name 2"
FROM world.country
WHERE Region LIKE '%Micronesia%/Carib%';
```

Resultado Esperado

Tras aplicar la corrección, el motor debe devolver el siguiente conjunto de resultados:

Region Name 1	Region Name 2
Micronesia	Caribbean


```

MariaDB [(none)]> SELECT DISTINCT (Region) FROM world.country WHERE LENGTH(TRIM(Region)) < 10;
+-----+
| Region |
+-----+
| Caribbean |
| Caribbean |
| Caribbean |
| Melanesia |
| Polynesia |
| Polynesia |
+-----+
33 rows in set (0.002 sec)

MariaDB [(none)]> SELECT DISTINCT (Region) FROM world.country WHERE LENGTH(TRIM(Region)) < 10;
+-----+
| Region |
+-----+
| Caribbean |
| Polynesia |
| Melanesia |
+-----+
3 rows in set (0.001 sec)

MariaDB [(none)]> SELECT
  -> substring_index(Region, "/", 1) AS "Region Name 1",
  -> substring_index(Region, "/", -1) AS "Region Name 2"
  -> FROM world.country
  -> WHERE Region = "Micronesia/Caribbean";
Empty set (0.000 sec)

MariaDB [(none)]> SELECT DISTINCT Region FROM world.country WHERE Region LIKE '%Carib%';
+-----+
| Region |
+-----+
| Caribbean |
| Micronesia/Caribbean |
+-----+
2 rows in set (0.000 sec)

MariaDB [(none)]> SELECT
  -> substring_index(Region, "/", 1) AS "Region Name 1",
  -> substring_index(Region, "/", -1) AS "Region Name 2"
  -> FROM world.country
  -> WHERE Region = "Micronesia/Caribbean";
+-----+
| Region Name 1 | Region Name 2 |
+-----+
| Micronesia | Caribbean |
+-----+
1 row in set (0.000 sec)

MariaDB [(none)]> SELECT
  -> substring_index(TRIM(Region), "/", 1) AS "Region Name 1",
  -> substring_index(TRIM(Region), "/", -1) AS "Region Name 2"
  -> FROM world.country
  -> WHERE Region LIKE "Micronesia/Carib%";
+-----+
| Region Name 1 | Region Name 2 |
+-----+
| Micronesia | Caribbean |
+-----+
1 row in set (0.000 sec)

MariaDB [(none)]>

```

Nota del Instructor: Como ingeniero, siempre valida tus datos con **LIKE** antes de realizar operaciones de transformación complejas. Esto garantiza que tus scripts de automatización no fallen por inconsistencias en el ingreso de datos manuales.

Respuestas Analíticas y Diagnóstico Técnico

- **¿Cuál es la ventaja de **TRIM()** antes de **LENGTH()**?** En bases de datos con ingresos manuales, es común que existan espacios en blanco accidentales (ej. " Asia " en lugar de "Asia"). **TRIM()** remueve estos caracteres invisibles antes de que **LENGTH()** realice el conteo, asegurando que el filtro sea exacto y profesional.
- **Impacto de **DISTINCT()** en el rendimiento:** **DISTINCT()** requiere que el motor de base de datos ordene y compare los resultados antes de entregarlos. Aunque es extremadamente útil para reportes limpios, en tablas con millones de registros debe usarse con moderación o combinarse con índices para evitar latencia.
- **Versatilidad de **SUBSTRING_INDEX()**:** Esta función es vital para procesar datos que no están en **Primera Forma Normal (1NF)**. Al poder usar índices negativos (como **-1**), permite extraer datos desde el final de la cadena hacia atrás, lo cual es ideal para extraer extensiones de archivos o apellidos en campos de nombre completo.

¡Felicidades! Has completado el laboratorio de funciones avanzadas de SQL, optimizando la extracción y formato de datos en AWS.